DATAFLOW

Calidad de datos y automatización con Python

Caso técnico · Analítica de datos · Portafolio profesional

8
REGISTROS

50 %
CALIDAD

19/19
PRUEBAS

Proyecto demostrativo con datos ficticios — no es un encargo de cliente real

Cuando los Excel no son confiables

Escenario: dos sucursales envían registros de ventas con errores y estructuras que deben consolidarse.

Fuentes dispersas

Cada sucursal entrega un archivo distinto. El proceso manual consume esfuerzo y dificulta revisar el origen de cada venta.

Errores en los registros

Cantidades inválidas, precios negativos e identificadores duplicados pueden afectar los informes posteriores.

Decisiones sin control

Sin validar la información, se arriesga la calidad de los indicadores que usan los equipos de negocio.

PREGUNTA CLAVE **¿Cómo asegurar un flujo consistente desde la carga hasta los reportes?**

De archivos dispersos a datos auditables

Flujo automatizado con Python + Pandas, accesible desde una interfaz web de Streamlit.

01 **Ingesta** → 02 **Consolidación** → 03 **Limpieza** → 04 **Validación** → 05 **Duplicados** → 06 **Reportes**

CONTROLES IMPLEMENTADOS

- Identificación de sucursal y trazabilidad
- Motivos de rechazo por registro
- Rechazo de duplicados configurable
- Tres Excel de salida revisables

ARQUITECTURA

Streamlit

↓

Motor Pandas · OpenPyXL

Una prueba: cuatro problemas detectados

Dos sucursales ficticias · Ocho registros procesados · Rechazo de duplicados activado

8 ANALIZADOS

4 VÁLIDOS

4 RECHAZADOS

CALIDAD DEL CONJUNTO DE PRUEBA



50 % cumplen las reglas · 50 % requieren revisión

HALLAZGOS

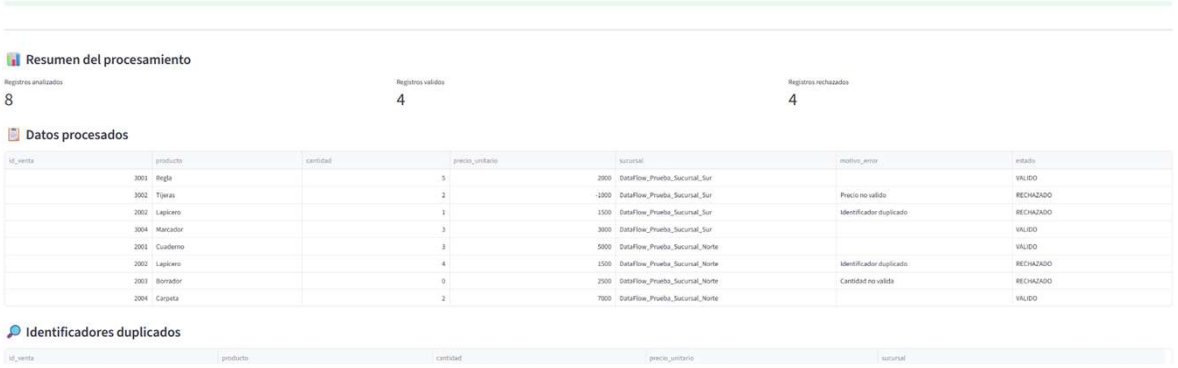
2 IDs duplicados · 1 precio inválido

1 cantidad inválida

Resultados auditados contra los tres archivos exportados.

Funcionamiento real + pruebas automatizadas

Evidencia de la interfaz publicada y la ejecución de Pytest en GitHub Actions.



Streamlit · Validación y motivos de rechazo

```
plugins: anyio-4.16.0
collecting ... collected 19 items

tests/test_procesador.py::test_validacion_y_reporte PASSED              [  5%]
tests/test_procesador.py::test_consolidar_ventas PASSED                 [ 10%]
tests/test_procesador.py::test_detectar_duplicados PASSED               [ 15%]
tests/test_procesador.py::test_validar_columnas PASSED                  [ 21%]
tests/test_procesador.py::test_procesar_dataflow_integrado PASSED       [ 26%]
tests/test_procesador.py::test_consolidacion_archivo_incompleto PASSED  [ 31%]
tests/test_procesador.py::test_exportar_resultados PASSED               [ 36%]
tests/test_procesador.py::test_limpiar_ventas PASSED                    [ 42%]
tests/test_procesador.py::test_limpieza_integrada_dataflow PASSED       [ 47%]
tests/test_procesador.py::test_validacion_identificadores_productos PASSED [ 52%]
tests/test_procesador.py::test_rechazo_configurable_duplicados PASSED   [ 57%]
tests/test_procesador.py::test_proceso_completo_dataflow PASSED         [ 63%]
tests/test_procesador.py::test_identificadores_con_espacios PASSED      [ 68%]
tests/test_procesador.py::test_sucursal_con_archivo_vacio PASSED        [ 73%]
tests/test_procesador.py::test_columnas_duplicadas_excel PASSED         [ 78%]
tests/test_procesador.py::test_normalizacion_automatica_encabezados PASSED [ 84%]
tests/test_procesador.py::test_archivo_excel_completamente_vacio PASSED  [ 89%]
tests/test_procesador.py::test_exportacion_excel_segura PASSED          [ 94%]
tests/test_procesador.py::test_archivo_excel_danado_mensaje_claro PASSED [100%]

============================== 19 passed in 2.36s ==============================
```

19/19 pruebas aprobadas · GitHub Actions

Una solución funcional. Competencias verificables.

Portafolio orientado a roles de analítica, calidad y automatización de datos.

Competencias demostradas

Python y Pandas · Transformaciones y reglas de negocio · Quality checks · Pruebas automatizadas · GitHub Actions · Streamlit

Aplicaciones prácticas

Consolidar archivos de sucursales, detectar inconsistencias, reducir trabajo manual de revisión y entregar reportes de calidad.

PORTAFOLIO PÚBLICO

github.com/ICamilo-M/dataflow-demo

Alcance: demostración con datos ficticios. No utilizar la aplicación pública con información confidencial.